1 统计量与抽样分布

1.1 基本概念：统计量、样本矩、经验分布函数

总体 X 的样本 X_1，X_2，…，X_n，则 $T(X_1, X_2, \cdots, X_n)$即为统计量

样本均值 $\mu = \overline{X}$

样本方差 $S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$

修正样本方差 $S^{*2}_n = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$

样本 k 阶原点矩 $A_k = \frac{1}{n}\sum_{i=1}^{n}X_i^k, (k = 1,2,...)$

样本 k 阶中心矩 $B_k = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^k, (k = 1,2,...)$

经验分布函数 $F_n(x) = \frac{v_n(x)}{n}, (-\infty < x < +\infty)$ 其中 $V_n(x)$表示随机事件 $\{X \le x\}$ 出现的次数,

显然 $V_n(x) \sim B(n, F(x))$,则有 $E[F_n(x)] = F(x)$ $D[F_n(x)] = \frac{1}{n}F(x)[1 - F(x)]$

补充：

- $ES_n^2 = \frac{n-1}{n}DX$ $ES_n^{*2} = DX$ $EX^2 = DX + (EX)^2$
- $S_n^2 = \frac{1}{n}\sum_{i=1}^{n}X_i^2 - \overline{X}^2$

- 二项分布 B(n,p): $P\{X = k\} = C_n^k p^k (1-p)^{n-k}, (k = 0,1,...,n)$

  EX=np DX=np(1-p)

- 泊松分布 $P(\lambda)$: $P\{X = k\} = \frac{\lambda^k}{k!}e^{-\lambda}, (k = 0,1,...)$

  $EX = \lambda$ $DX = \lambda$

- 均匀分布 U(a,b): $f(x) = \frac{1}{b-a}, (a < x < b)$

  $EX = \frac{a+b}{2}$ $DX = \frac{1}{12}(b-a)^2$

- 指数分布: $f(x) = \lambda e^{-\lambda x}, (x > 0) \leftrightarrow F(x) = 1 - e^{-\lambda x}, (x > 0)$

  $EX = \frac{1}{\lambda}$ $DX = \frac{1}{\lambda^2}$

- 正态分布 $N(\mu,\sigma^2)$: $f(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}$ $EX=\mu$ $DX=\sigma^2$

$E(\frac{nS_n^2}{\sigma^2})=n-1\Rightarrow ES_n^2=\frac{n-1}{n}\sigma^2$ $D(\frac{nS_n^2}{\sigma^2})=2(n-1)\Rightarrow DS_n^2=\frac{2(n-1)}{n^2}\sigma^4$

当 $\mu=0$ 时，$EX=0$ $EX^2=\sigma^2$ $EX^4=3\sigma^4$ $E|X|=\sqrt{\frac{2}{\pi}}\sigma$ $D|X|=(1-\frac{2}{\pi})\sigma^2$

1.2 统计量：充分统计量、因子分解定理、完备统计量、指数型分布族

T 是 θ 的充分统计量 $\Leftrightarrow$ $f(x_1,x_2,...,x_n|T=t)$ 与 θ 无关

T 是 θ 的完备统计量 $\Leftrightarrow$ 要使 E[g(T)]=0,必有 g(T)=0

$L(\theta)=\prod_{i=1}^{n}f(x_i;\theta)=h(x_1,x_2,...,x_n)g(T(x_1,x_2,...,x_n);\theta)$ 且 h 非负 $\Leftrightarrow$ T 是 θ 的充分统计量

$\prod_{i=1}^{n}f(x_i;\theta)=C(\theta)\exp\{b(\theta)T(x_1,x_2,...,x_n)\}h(x_1,x_2,...,x_n)$ $\Leftrightarrow$ T 是 θ 的充分完备统计量

$\prod_{i=1}^{n}f(x_i;\theta)=C(\theta)\exp\{b_1(\theta)T_1(x_1,x_2,...,x_n)+b_2(\theta)T_2(x_1,x_2,...,x_n)\}h(x_1,x_2,...,x_n)$

$\Leftrightarrow$ (T_1,T_2) 是 $\theta=(\theta_1,\theta_2)$ 的充分完备统计量

1.3 抽样分布：χ^2 分布，t 分布，F 分布，分位数，正态总体样本均值和方差的分布，非正态总体样本均值的分布

χ^2 分布：$\chi^2=X_1^2+X_2^2+...+X_n^2\sim\chi^2(n)$ $f(x)=\frac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})}e^{-\frac{x}{2}}x^{\frac{n}{2}-1}(x>0)$

$E\chi^2=n$ $D\chi^2=2n$

T 分布：$T=\frac{X}{\sqrt{Y/n}}\sim t(n)$ 当 n>2 时，ET=0 $DT=\frac{n}{n-2}$

F 分布：$F=\frac{X/n_1}{Y/n_2}\sim F(n_1,n_2)$ $\frac{1}{F}=F(n_2,n_1)$

补充：

- Z=X+Y 的概率密度 $f_z(z)=\int_{-\infty}^{+\infty}f(x,z-x)dx=\int_{-\infty}^{+\infty}f(z-y,y)dy$ f(x,y)是 X 和 Y 的联合概率密度

- $Z=\frac{Y}{X}$ 的概率密度 $f_z(z)=\int_{-\infty}^{+\infty}f(x,xz)|x|dx$
- $y=g(x)$ 的概率密度 $f_y(y)=f_x(g^{-1}(y))|[g^{-1}(y)]'|$
- Γ 函数：$\Gamma(\alpha)=\int_0^{+\infty}x^{\alpha-1}e^{-x}dx$　$\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$　$\Gamma(n)=(n-1)!,\Gamma(1)=1$
- B 函数：$B(\alpha,\beta)=\int_0^1 x^{\alpha-1}(1-x)^{\beta-1}dx$　$B(\alpha,\beta)=\frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$

1.4 次序统计量及其分布：次序统计量、样本中位数 $\tilde{X}$、样本极差 R

$X_{(k)}$的分布密度：$f_{x_{(k)}}(x)=\frac{n!}{(k-1)!(n-k)!}[F(x)]^{k-1}[1-F(x)]^{n-k}f(x),(k=1,2,...,n)$

$X_{(1)}$的分布密度：$f_{x_{(1)}}(x)=nf(x)[1-F(x)]^{n-1}$

$X_{(n)}$的分布密度：$f_{x_{(n)}}(x)=nf(x)[F(x)]^{n-1}$

2 参数估计

2.1 点估计与优良性：概念、无偏估计、均方误差准则、相合估计(一致估计)、渐近正态估计

$\hat{\theta}$的均方误差：$MSE(\hat{\theta},\theta)=E(\hat{\theta}-\theta)^2=D\hat{\theta}+(E\hat{\theta}-\theta)^2$

若$\hat{\theta}$是无偏估计，则$MSE(\hat{\theta},\theta)=D\hat{\theta}$

对于θ的任意一个无偏估计量$\hat{\theta}$，有$D\hat{\theta}^*\le D\hat{\theta}$，则$\hat{\theta}^*$是$\theta$的最小方差无偏估计，记 MVUE

相合估计(一致估计):$\lim_{n\to\infty}E\theta_n=\theta$　$\lim_{n\to\infty}D\hat{\theta}_n=0$

2.2 点估计量的求法：矩估计法、最大似然估计法

矩估计法：

① 求出总体的 k 阶原点矩:$a_k=EX^k=\int_{-\infty}^{+\infty}x^kdF(x;\theta_1,\theta_2,...,\theta_m)$

② 解方程组$a_k=\frac{1}{n}\sum_{i=1}^{n}X_i^k$ (k=1,2,...,m)，得$\hat{\theta}_k=\hat{\theta}_k(X_1,X_2,...,X_n)$即为所求

最大似然估计法：

① 写出似然函数$L(\theta)=\prod_{i=1}^{n}f(x_i;\theta)$，求出 lnL 及似然方程$\left.\frac{\partial\ln L}{\partial\theta_i}\right|_{\theta=\hat{\theta}}=0$　i=1,2,...,m

② 解似然方程得到$\hat{\theta}_i(x_1,x_2,...,x_n)$，即最大似然估计$\hat{\theta}_i(X_1,X_2,...,X_n)$　i=1,2,...,m

补充：

■ 似然方程无解时，求出θ的定义域中使得似然函数最大的值，即为最大似然估计

2.3MVUE 和有效估计：最小方差无偏估计、有效估计

T 是θ的充分完备统计量，$\hat{\theta}$是θ的一个无偏估计 $\Leftrightarrow \hat{\theta}^* = E(\hat{\theta}\,|\,T)$ 为θ的惟一的 MVUE

最小方差无偏估计的求解步骤：

① 求出参数θ的充分完备统计量 T

② 求出$ET = g(\theta)$，则$\hat{\theta} = g^{-1}(T)$是θ的一个无偏估计

或求出一个无偏估计，然后改写成用 T 表示的函数

③ 综合，$E[g^{-1}(T)\big|T] = g^{-1}(T)$是$\theta$的 MVUE

或者：求出θ的矩估计或 ML 估计，再求效率，为 1 则必为 MVUE

T 是 $g(\theta)$ 的一个无偏估计，则满足信息不等式 $D[T(X)] \geq \dfrac{[g'(\theta)]^2}{nI(\theta)}$，其中

$I(\theta) = E\left[\dfrac{\partial \ln f(X;\theta)}{\partial\theta}\right]^2$ 或 $I(\theta) = -E\left[\dfrac{\partial^2 \ln f(X;\theta)}{\partial\theta^2}\right] > 0$，$f(X;\theta)$为样本的联合分布。

最小方差无偏估计 $\Leftarrow$ 达到罗-克拉姆下界 $\Leftrightarrow$ 有效估计量 $\Leftrightarrow$ 效率为 1

无偏估计$\hat{\theta}$的效率：$e(\hat{\theta}) = \dfrac{1}{nI(\theta)}\Big/D\hat{\theta}$

$\hat{\theta}$是θ的最大似然估计，且$\hat{\theta}$是θ的充分统计量 $\Leftrightarrow$ $\hat{\theta}$是θ的有效估计

2.4 区间估计：概念、正态总体区间估计(期望、方差、均值差、方差比)及单侧估计、非正态总体参数和区间估计

一个总体的情况：$X \sim N(\mu,\sigma^2)$

σ^2 已知，求 μ 的置信区间：$\dfrac{\overline{X}-\mu_0}{\sigma_0/\sqrt{n}} \sim N(0,1) \Rightarrow \left|\overline{X}-\mu_0\right| < \dfrac{\sigma_0}{\sqrt{n}}u_{\frac{\alpha}{2}}$

σ^2 未知，求 μ 的置信区间：$\dfrac{\overline{X}-\mu_0}{S_n^*/\sqrt{n}} \sim t(n-1) \Rightarrow \left|\overline{X}-\mu_0\right| < \dfrac{S_n^*}{\sqrt{n}}t_{\frac{\alpha}{2}}(n-1)$

μ 已知，求 σ^2 的置信区间：$\dfrac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma^2} \sim \chi^2(n) \Rightarrow \dfrac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{\frac{\alpha}{2}}(n)} < \sigma^2 < \dfrac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{1-\frac{\alpha}{2}}(n)}$

μ 未知，求 σ^2 的置信区间：

$$\frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\sigma^2} \sim \chi^2(n-1) \Rightarrow \frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\chi^2_{\frac{\alpha}{2}}(n-1)} < \sigma^2 < \frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\chi^2_{1-\frac{\alpha}{2}}(n-1)}$$

两个总体的情况：$X \sim N(\mu_1, \sigma_1^2)$，$Y \sim N(\mu_2, \sigma_2^2)$

σ_1^2, σ_2^2 均已知时，求 $\mu_1 - \mu_2$ 的区间估计：

$$\frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1) \Rightarrow \left|\overline{X} - \overline{Y} - (\mu_1 - \mu_2)\right| < \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} u_{\frac{\alpha}{2}}$$

$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知时，求 $\mu_1 - \mu_2$ 的区间估计：

$$\frac{\overline{X} - \overline{Y} - (\mu_1 - \mu_2)}{\sqrt{(n_1 - 1)S_{1n_1}^{*2} + (n_2 - 1)S_{2n_2}^{*2}}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} \sim t(n_1 + n_2 - 2)$$

μ_1, μ_2 未知时，求 $\frac{\sigma_1^2}{\sigma_2^2}$：

$$\frac{S_{2n_2}^{*2}\sigma_1^2}{S_{1n_1}^{*2}\sigma_2^2} \sim F(n_2 - 1, n_1 - 1) \Rightarrow \frac{S_{1n_1}^{*2}}{S_{2n_2}^{*2}} F_{1-\frac{\partial}{2}}(n_2 - 1, n_1 - 1) < \frac{\sigma_1^2}{\sigma_2^2} < \frac{S_{1n_1}^{*2}}{S_{2n_2}^{*2}} F_{\frac{\partial}{2}}(n_2 - 1, n_1 - 1)$$

非正态总体的区间估计：

当 $n \to \infty$ 时，$\frac{\overline{X} - \mu}{S_n / \sqrt{n}} \xrightarrow{L} N(0,1) \Rightarrow \left|\overline{X} - \mu\right| < \frac{S_n}{\sqrt{n}} u_{\frac{\alpha}{2}}$ $\left(\lim_{n \to \infty} \frac{S_n}{S_{n-1}} = 1\right)$，故用 S_n 代替 S_{n-1}

$$\frac{\overline{X} - \frac{m}{n}}{\sqrt{\frac{1}{n}\frac{m}{n}\left(1 - \frac{m}{n}\right)}} \sim N(0,1) \Rightarrow \left(\frac{m}{n} \pm u_{\frac{\alpha}{2}} \sqrt{\frac{1}{n}\frac{m}{n}\left(1 - \frac{m}{n}\right)}\right)$$

3 统计决策与贝叶斯估计

3.1 统计决策的基本概念：三要素、统计决策函数及风险函数

三要素：样本空间和分布族、行动空间（判决空间）、损失函数 $L(\theta, d)$

统计决策函数 d(X):本质上是一个统计量，可用来估计未知参数

风险函数：$R(\theta, d) = E_\theta[L(\theta, d(X))]$ 是关于 θ 的函数

3.2 贝叶斯估计：先验分布与后验分布、贝叶斯风险、贝叶斯估计

① 求样本 X=(X_1,X_2,...,X_n)的分布：$q(x \mid \theta) = \prod_{i=1}^{n} f(x_i \mid \theta)$

② 样本 X 与 θ 的联合概率分布：$f(x, \theta) = h(\theta \mid x) m(x) = q(x \mid \theta) \pi(\theta)$

③ 求 $f(x,\theta)$ 关于 x 的边缘密度 $m(x)=\int_{\Theta} f(x,\theta)d\theta$

④ θ 的后验密度为：$h(\theta\mid x)=\dfrac{f(x,\theta)}{m(x)}$

取 $L(\theta,d)=(\theta-d)^2$ 时

θ 的贝叶斯估计为：$\hat{\theta}=E(\theta\mid x)=\int_{\Theta}\theta h(\theta\mid x)d\theta$

贝叶斯风险为：$\begin{cases}R(\theta,d)=E_{\theta}(\theta-d)^2\\ R_B(d)=E[R(\theta,d)]=\int_{\Theta}E_{\theta}(\theta-d)^2h(\theta\mid x)d\theta\end{cases}$

取 $L(\theta,d)=\lambda(\theta)(\theta-d)^2$ 时，贝叶斯估计为：$\hat{\theta}=\dfrac{E[\lambda(\theta)\theta\mid x]}{E[\lambda(\theta)\mid x]}$

补充：

- $C(\theta)$ 的贝叶斯估计：取损失函数 $L(\theta,d)=(C(\theta)-d)^2$，则贝叶斯估计为

  $\hat{C}(\theta)=E[C(\theta)\mid x]=\int_{\Theta}C(\theta)h(\theta\mid x)d\theta$

- $\hat{\theta}=E(\theta\mid x)=\int_{\Theta}h(\theta\mid x)d\theta=\int_{\Theta}\dfrac{\theta f(x,\theta)}{m(x)}d\theta=\dfrac{\int_{\Theta}\theta f(x,\theta)d\theta}{\int_{\Theta}f(x,\theta)d\theta}$

3.3minimax 估计

对决策空间中的决策函数 $d_1(X),d_2(X),\ldots$，分别求出在 Θ 上的最大风险值 $\max\limits_{\theta\in\Theta}R(\theta,d)$

在所有的最大风险值中选取相对最小值，此值对应的决策函数就是最小最大决策函数。

4 假设检验

4.1 基本概念：零假设(H_0)与备选假设(H_1)、检验规则、两类错误、势函数

零假设通常受到保护，而备选假设是当零假设被拒绝后才能被接受。

检验规则：构造一个统计量 $T(X_1,X_2,\ldots,X_3)$，当 H_0 服从某一分布，当 H_0 不成立时，T 的偏大偏小特征。据此，构造拒绝域 W

第一类错误（弃真错误）：$P\{T\in W\mid H_0\text{为真}\}$

第二类错误（存伪错误）：$P\{T\notin W\mid \mathrm{H}_0\text{为假}\}$

势函数：$\beta(\theta)=E_{\theta}(\delta(X))=P_{\theta}\{X\in W\}$ $\delta(X)=\begin{cases}1, & X\in W.\\ 0, & X\notin W.\end{cases}$

当 $\theta\in\Theta_0$ 时，$\beta(\theta)$ 为犯第一类错误的概率

当$\theta \in \Theta_1$时，$1-\beta(\theta)$为犯第二类错误的概率

4.2 正态总体均值与方差的假设检验：t 检验、X^2 检验、F 检验、单边检验

一个总体的情况：$X \sim N(\mu, \sigma^2)$

σ^2 已知，检验 $H_0: \mu = \mu_0 \leftrightarrow H_1: \mu \neq \mu_0$：$U = \dfrac{\overline{X} - \mu_0}{\sigma_0 / \sqrt{n}} \sim N(0,1)$

σ^2 未知，检验 $H_0: \mu = \mu_0 \leftrightarrow H_1: \mu \neq \mu_0$：$T = \dfrac{\overline{X} - \mu_0}{S_n^* / \sqrt{n}} \sim t(n-1)$

μ 已知，检验 $H_0: \sigma^2 = \sigma_0^2 \leftrightarrow H_1: \sigma^2 \neq \sigma_0^2$：$\chi^2 = \dfrac{\sum_{i=1}^{n}(X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$

μ 未知，检验 $H_0: \sigma^2 = \sigma_0^2 \leftrightarrow H_1: \sigma^2 \neq \sigma_0^2$：$\chi^2 = \dfrac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{\sigma^2} \sim \chi^2(n-1)$

两个总体的情况：$X \sim N(\mu_1, \sigma_1^2)$，$Y \sim N(\mu_2, \sigma_2^2)$

$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知时，检验 $H_0: \mu_1 = \mu_2 \leftrightarrow H_1: \mu_1 \neq \mu_2$：

$$T = \frac{\overline{X} - \overline{Y}}{\sqrt{(n_1-1)S_{1n_1}^{*2} + (n_2-1)S_{2n_2}^{*2}}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} \sim t(n_1 + n_2 - 2)$$

μ_1, μ_2 未知时，检验 $H_0: \sigma_1^2 = \sigma_2^2 \leftrightarrow H_1: \sigma_1^2 \neq \sigma_2^2$：$F = \dfrac{S_{1n_1}^{*2}}{S_{2n_2}^{*2}} \sim F(n_1 - 1, n_2 - 1)$

单边检验：举例说明，σ^2 已知，检验 $H_0: \mu \leq \mu_0 \leftrightarrow H_1: \mu > \mu_0$：

构造 $U_1 = \dfrac{\overline{X} - \mu}{\sigma_0 / \sqrt{n}} \sim N(0,1)$，给定显著性水平 α，有 $P\{U_1 > u_\alpha\} = \alpha$。当 H_0 成立时 $U_1 = \dfrac{\overline{X} - \mu}{\sigma_0 / \sqrt{n}} \geq \dfrac{\overline{X} - \mu_0}{\sigma_0 / \sqrt{n}} \overset{def}{\Rightarrow} U$，因此 $P\{U > u_\alpha\} \leq P\{U_1 > u_\alpha\} = \alpha$。故拒绝域为 $W = \{U > u_\alpha\}$

4.3 非参数假设检验方法：χ^2 拟合优度检验、科尔莫戈罗夫检验、斯米尔诺夫检验

χ^2 拟合优度检验: $H_0: p_i = p_{i0} \leftrightarrow H_1: p_i \neq p_{i0}$ $W = \{\sum_{i=1}^{m} \dfrac{(Ni - np_{i0})^2}{np_{i0}} > \chi_\alpha^2(m - r - 1)\}$

其中 N_i 表示样本中取值为 i 的个数，r 表示分布中未知参数的个数

科尔莫戈罗夫检验：$H_0: F(x)=F_0(x) \leftrightarrow H_1: F(x)\neq F_0(x)$ 实际检验的是 $F_n(x)=F_0(x)$

$$W=\{\lim_{n\to\infty}\sup_{-\infty<x<+\infty}\left|F_n(x)-F_0(x)\right|>D_{n,\alpha}\}$$

斯米尔诺夫检验：$H_0: F(x)=G(x) \leftrightarrow H_1: F(x)\neq G(x)$ 实际检验的是 $F_n(x)=G_n(x)$

$$W=\{\lim_{n\to\infty}\sup_{-\infty<x<+\infty}\left|F_{n_1}(x)-G_{n_2}(x)\right|>D_{n_1,n_2,\alpha}\}$$

4.4 似然比检验

明确零假设和备选假设：$H_0:\theta\in\Theta_0 \leftrightarrow H_1:\theta\in\Theta_1$

构造似然比：$\lambda=\dfrac{L_1(x_1,...,x_n)}{L_0(x_1,...,x_n)}=\dfrac{\sup_{\theta\in\Theta}L(x_1,...,x_n;\theta)}{\sup_{\theta\in\Theta_0}L(x_1,...,x_n;\theta)}$

拒绝域：$W=\{\lambda(x_1,...,x_n)>\lambda_\alpha\}$

5 方差分析

5.1 单因素方差分析：数学模型、离差平方和分解、显著性检验、参数估计

数学模型 $\begin{cases}X_{ij}=\mu+\alpha_i+\varepsilon_{ij}\\ \varepsilon_{ij}\sim N(0,\sigma^2) \quad ,(i=1,2,...,m;j=1,2,...,n_i)\ H_0:\ \alpha_1=\alpha_2=...=\alpha_n\\ 各\varepsilon_{ij}相互独立\end{cases}$

总离差平方和 $Q_T=\sum_{i=1}^{m}\sum_{j=1}^{n_i}(X_{ij}-\overline{X})^2 \qquad Q_T=Q_E+Q_A$

组内离差平方和 $Q_E=\sum_{i=1}^{m}\sum_{j=1}^{n_i}(X_{ij}-\overline{X_i})^2 \quad E(\dfrac{Q_E}{n-r})=\sigma^2$

组间离差平方和 $Q_A=\sum_{i=1}^{m}n_i(\overline{X_i}-\overline{X})^2$ 当 H_0 成立时，$E(\dfrac{Q_A}{r-1})=\sigma^2$

构造统计量 $F=\dfrac{Q_A/(r-1)}{Q_E/(n-r)}=\dfrac{\overline{Q_A}}{\overline{Q_E}}\sim F(r-1,n-r)$，当 H_0 不成立时，有偏大特征

$\overline{X_i}-\overline{X_k}\sim N(\mu_i-\mu_k,(\dfrac{1}{n_i}+\dfrac{1}{n_k})\sigma^2)$ 且 $\dfrac{Q_E}{\sigma^2}\sim\chi^2(n-r)$

$$\Rightarrow T=\frac{X_i-X_k-(\mu_i-\mu_k)}{\sqrt{(\dfrac{1}{n_i}+\dfrac{1}{n_k})Q_E}}\sim t(n-r)$$

应用：

- 若原始数据比较大而且集中，可减去同一数值 $X_{ij}^{'}=X_{ij}-k$ 再解题

- 辅助量：$P=\frac{1}{n}(\sum_{i=1}^{m}\sum_{j=1}^{n_i}X_{ij})^2, Q=\sum_{i=1}^{m}\frac{1}{n_i}(\sum_{j=1}^{n_i}X_{ij})^2, R=\sum_{i=1}^{m}\sum_{j=1}^{n_i}X_{ij}{}^2$

$$Q_A=Q-P, Q_E=R-Q, Q_T=R-P$$

5.2 两因素方差分析：数学模型、离差平方和分解、显著性检验

数学模型 $\begin{cases} X_{ij}=\mu+\alpha_i+\beta_i+\varepsilon_{ij} \\ \varepsilon_{ij}\sim N(0,\sigma^2) \\ 各\varepsilon_{ij}相互独立 \end{cases}$,(i=1,2,...,r;j=1,2,...,s) $\begin{cases} H_{01}:\alpha_1=\alpha_2=...=\alpha_n \\ H_{02}:\beta_1=\beta_2=...=\beta_n \end{cases}$

总离差平方和 $Q_T=\sum_{i=1}^{r}\sum_{j=1}^{s}(X_{ij}-\bar{X})^2$ $Q_T=Q_E+Q_B+Q_A$

组内离差平方和 $Q_E=\sum_{i=1}^{m}\sum_{j=1}^{n_i}(X_{ij}-\overline{X_{i\bullet}}-\overline{X_{\bullet j}}+\overline{X_i})^2$ $E(\frac{Q_E}{(r-1)(s-1)})=\sigma^2$

因素 B 引起的离差平方和 $Q_B=\sum_{j=1}^{s}r(\overline{X_{\bullet j}}-\overline{X})^2$ 当 H_0 成立时，$E(\frac{Q_B}{s-1})=\sigma^2$

因素 A 引起的离差平方和 $Q_A=\sum_{i=1}^{r}s(\overline{X_{i\bullet}}-\overline{X})^2$ 当 H_0 成立时，$E(\frac{Q_A}{r-1})=\sigma^2$

辅助量：$P=\frac{1}{n}\left(\sum_{i=1}^{r}\sum_{j=1}^{s}X_{ij}\right)^2, Q_I=\sum_{i=1}^{r}\frac{1}{s}\left(\sum_{j=1}^{s}X_{ij}\right)^2, Q_{II}=\sum_{j=1}^{s}\frac{1}{r}\left(\sum_{i=1}^{r}X_{ij}\right)^2, R=\sum_{i=1}^{r}\sum_{j=1}^{s}X_{ij}^2$

$$Q_A=Q_I-P, Q_B=Q_{II}-P, Q_E=R-Q_I-Q_{II}-P$$

构造统计量：$\begin{cases} F_A=\frac{Q_A/(r-1)}{Q_E/(r-1)(s-1)}=\frac{\overline{Q_A}}{\overline{Q_E}}\sim F(r-1,(r-1)(s-1)) \\ F_B=\frac{Q_B/(s-1)}{Q_E/(r-1)(s-1)}=\frac{\overline{Q_A}}{\overline{Q_E}}\sim F(s-1,(r-1)(s-1)) \end{cases}$

6 回归分析

6.1 一元线性回归：回归模型、未知参数的估计(β、α、σ²)、参数估计量的分布(β α Y0 σ 2 σ *2)

回归模型：$\begin{cases} Y_i=\alpha+\beta x_i+\varepsilon_i \\ \varepsilon_i\sim N(0,\sigma^2) \\ 各\varepsilon_i相互独立 \end{cases}$ i=1,2,...,n.

(α,β)的估计：$\begin{cases}\hat{\beta}=\dfrac{\sum_{i=1}^{n}(x_i-\bar{x})(Y_i-\bar{Y})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\\ \hat{\alpha}=\bar{Y}-\hat{\beta}\bar{x}\end{cases}$ (α,β)分布：$\begin{cases}\hat{\beta}\sim N(\beta,\dfrac{\sigma^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2})\\ \hat{\alpha}\sim N(\alpha,[\dfrac{1}{n}+\dfrac{(\bar{x})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}]\sigma^2)\end{cases}$

σ^2的估计：$\hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(Y_i-\bar{Y})^2-\hat{\beta}^2(\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2)=S_{nY}^2-\hat{\beta}^2S_{nx}^2$

$$E\hat{\sigma}^2=\frac{n-2}{n}\sigma^2 \quad E\hat{\sigma}^{*2}=\sigma^2$$

6.2 多元线性回归：回归模型、参数估计、分布

回归模型：$\begin{cases}Y_i=X_i\beta+\varepsilon_i\\ \varepsilon_i\sim N(0,\sigma^2I_n)\ \text{i=1,2,...,n.}\\ \text{各}\varepsilon_i\text{相互独立}\end{cases}$

参数估计：$X^TY=(X^TX)\hat{\beta}\Rightarrow\hat{\beta}=(X^TX)^{-1}X^TY$

7 多元分析初步

7.1 定义及性质：定义、性质

$X\sim N_p(\mu,\Sigma)$其中μ为X的均值向量，Σ为X的协方差矩阵

Y=CX+b，则$Y\sim N_p(C\mu+b,C\Sigma C^T)$

若$|\Sigma|\neq 0$，刚$\eta\overset{def}{\Rightarrow}(X-\mu)\Sigma^{-1}(X-\mu)\sim\chi^2(p)$

7.2 参数的估计与假设检验：μ、Σ的估计、正态总体均值向量的假设检验

样本均值向量$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$ 样本离差阵$S=\sum_{k=1}^{n}(X_k-\bar{X})(X_k-\bar{X})^T$

最大似然估计$\hat{\mu}=\bar{X}\quad\hat{\Sigma}=\dfrac{S}{n}$

最小方差无偏估计$\hat{\mu}=\bar{X}\quad\hat{\Sigma}=\dfrac{S}{(n-1)}$

$\bar{X}\sim N(\mu,\frac{1}{n}\Sigma)\quad S=\sum_{i=1}^{n-1}Y_iY_i^T$

$\eta=n(\bar{X}-\mu_0)^T\Sigma^{-1}(\bar{X}-\mu_0)\sim\chi^2(p)$

$F=\dfrac{n-p}{(n-1)}[n(n-1)(\bar{X}-\mu_0)TS^{-1}(\bar{X}-\mu_0)]^2\sim F(p,n-p)$

$$\chi^2_{mn} = \frac{mn}{m+n}(\overline{X} - \overline{Y})T\Sigma^{-1}(\overline{X} - \overline{Y}) \sim \chi^2(p)$$

$$F = \frac{mn(m+n-p-1)}{p(m+n)(m+n-2)}(\overline{X} - \overline{Y})^T S^{-1}(\overline{X} - \overline{Y})$$